

# [PSZT-P] Kiedy się poddać?

Piotr Frątczak

Bartosz Świtalski

26 listopada 2020

## 1 Opis problemu

Algorytmy ewolucyjne w klasycznym wydaniu nie mogą same zdecydować, kiedy zakończyć swoje działanie. W związku z tym należy rozważyć implementację określonego z góry kryterium. Nie istnieje uniwersalne kryterium wykrywania bezcelowości dalszej pracy algorytmu ewolucyjnego. W naszej pracy proponujemy przykładowe rozwiązania, zaimplementujemy je oraz dokonamy analizy ich działania.

## 2 Decyzje projektowe

Optymalizacja zostanie przeprowadzona na funkcjach z [cec2005](#). Zaimplementowana została strategia ewolucyjna  $(\mu + \lambda)$ . Przyjęty budżet możliwych ewaluacji funkcji celu dla pojedynczej próby optymalizacji wynosi  $10000 \times \text{wymiarowość zadania}$ . Skupiamy się na wymiarowości  $D = 10$ . Podczas jednego uruchomienia programu dokonujemy uśrednienia wyników z 51 wywołań algorytmu.

## 3 Cele eksperymentu

Implementacja kryteriów przerwań optymalizacji. Dobranie przykładowych parametrów dla odpowiednich kryteriów. Zbadanie wpływu tychże kryteriów na ogólny czas optymalizacji oraz dokładność uzyskanego wyniku (optimum).

## 4 Użycie

```
/when-to-surrender$
```

```
python3 when-to-surrender/main.py
```

```
<funkcja> <kryterium> <p1> <p2> <p3> <p4>
```

## Oznaczenia argumentów

<funkcja> - optymalizowana funkcja (dozwolone wartości:  $F_4^1$ ,  $F_5^2$ ,  $F_6^3$ ).

<kryterium> - kryterium przerywania (dozwolone wartości: *k-iter*, *sd*, *best-worst*, *variance*).

< $p_i$ > - kolejne wartości parametru do wcześniej sprecyzowanego kryterium.

## Użycie skryptu

```
/when-to-surrender$
```

```
./xscript.sh  
# po wykonaniu  
./xclean.sh
```

## Komentarz do użycia

Skrypt umożliwia uruchomienie optymalizacji wszystkich dostępnych funkcji (3) według wszystkich zaimplementowanych kryteriów (4) z wcześniej określonymi parametrami. Pojedyncze uruchomienie skryptu jest dość kosztowne czasowo, więc w celu skrócenia czasu wykonania zalecany jest np. przydział zadań do różnych rdzeni (komenda `taskset`), ale optymalizacja czasu wykonania wielu uruchomień na raz nie jest tematem projektu.

Wygenerowane dane zostaną zapisane do plików w folderze `output`. Do czyszczenia służy skrypt `xclean.sh`.

## 5 Kryteria przerywań

- ***K-iterations* (*K-iteracji*).** Wykorzystane jako kryterium bazowe. Kryterium jest spełnione, jeśli nie ma poprawy wartości funkcji celu przez  $K$  kolejnych iteracji. Należy wybrać odpowiednią wartość  $K$  przy założeniu, że niemożliwe jest uzyskanie lepszego wyniku po  $K$  kolejnych iteracjach.
- **Standard Deviation (Odchylenie Standardowe).** Kryterium jest spełnione, jeżeli odchylenie standardowe wartości każdej z cech osobników obecnej generacji jest mniejsze lub równe niż dane próg  $\epsilon \geq 0$ .
- **Best-worst (Najlepszy-Najgorszy).** Kryterium jest spełnione, gdy różnica funkcji celu między najlepszym i najgorszym osobnikiem jest mniejsza lub równa niż dany próg  $\epsilon \geq 0$ .

---

<sup>1</sup>Shifted Schwefel's Problem 1.2 with Noise in Fitness

<sup>2</sup>Schwefel's Problem 2.6 with Global Optimum on Bounds


<sup>3</sup>Shifted Rosenbrock's Function

- **Fit-Variance (Wariancja Dopasowania).** Kryterium uwzględniające zróżnicowanie funkcji celu wszystkich osobników populacji. Jest spełnione, jeśli wariancja funkcji celu dla wszystkich osobników w pokoleniu jest mniejsza lub równa niż dany próg  $\epsilon$  przy czym  $1 \gg \epsilon \geq 0$ .


## 6 Uzyskane wyniki

Uzyskane wyniki dla uruchomień funkcji według każdego kryterium z różnymi parametrami zostały zebrane w pojedynczy plik `output.pdf` i zostaną omówione w dalszej części tego sprawozdania.

### Przykłady działania strategii ewolucyjnej $(\mu + \lambda)$



Rysunek 1: Dopasowanie najlepszego osobnika populacji w zależności od liczby ewaluacji funkcji celu dla  $F_4$ .



Rysunek 2: Dopasowanie średniego osobnika populacji w zależności od liczby ewaluacji funkcji celu dla  $F_6$ .

## 7 Wnioski

### Objaśnienia

`best fit` - najlepsze znalezione optimum

`best fit mean` - średnia najlepszych znalezionych optimów

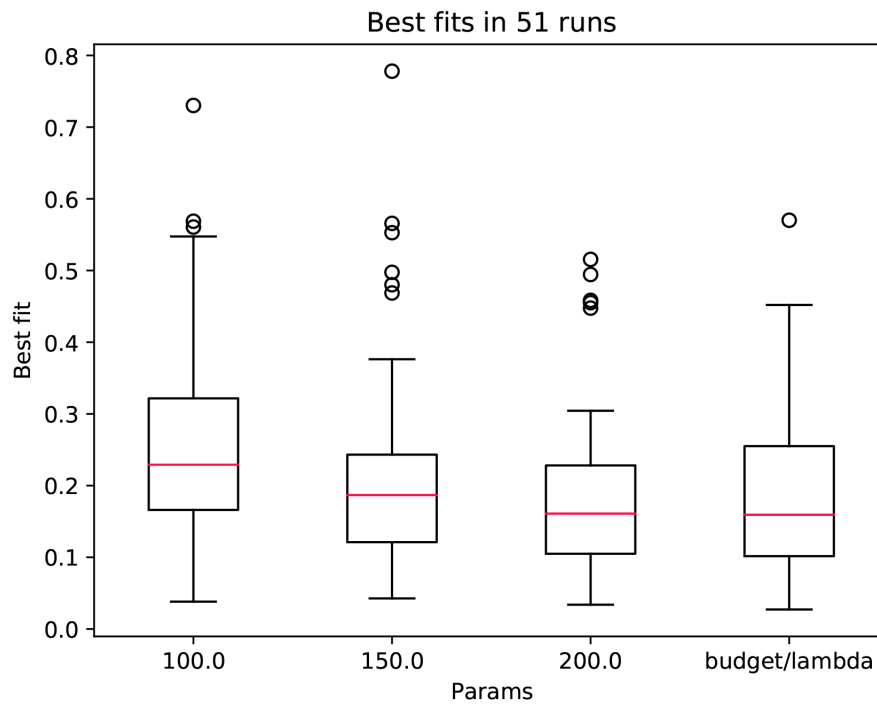
`best fit std. deviation` - odchylenie standardowe najlepszych znalezionych optimów

`budget use` - średnie wykorzystanie budżetu

## Wnioski do kryterium $K$ -iteracji

k value	best fit	best fit mean	best fit std. deviation	budget use mean
100	0.04	0.26	0.14	84.74%
150	0.04	0.22	0.15	95.41%
<b>200</b>	<b>0.03</b>	<b>0.19</b>	<b>0.11</b>	<b>96.63%</b>
budget/lambda	0.03	0.19	0.12	99.98%


Tablica 1: Porównanie najlepszych wartości parametru  $k$  dla  $F_4$



Rysunek 3: Wartości najlepszego dopasowania funkcji  $F_4$  wg kryterium  $K$ -iteracji. Najlepszy parametr  $k \approx 200$ , wykorzystanie  $\approx 96.63\%$  budżetu.

k value	best fit	best fit mean	best fit std. deviation	budget use mean
<b>200</b>	<b>1.02</b>	<b>3.32</b>	<b>1.33</b>	<b>94.65%</b>
300	0.61	3.5	1.74	99.52%
400	0.6	3.49	1.87	99.87%
budget/lambda	1.06	3.56	2.38	99.98%

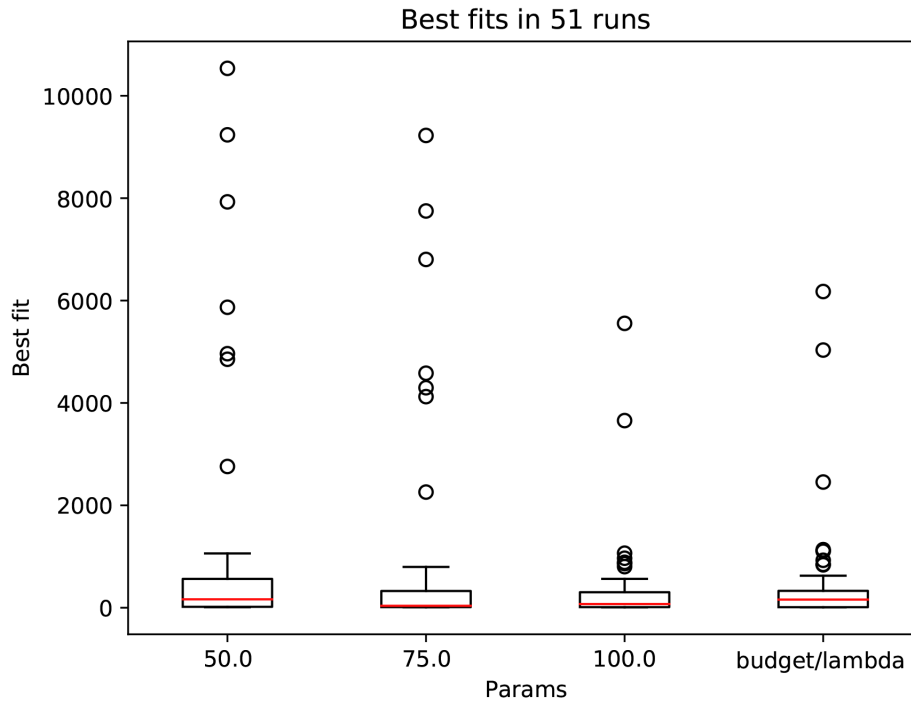
Tablica 2: Porównanie najlepszych wartości parametru  $k$  dla  $F_5$



Rysunek 4: Wartości najlepszego dopasowania funkcji  $F_5$  wg kryterium  $K$ -iteracji. Najlepszy parametr  $k \approx 200$ , wykorzystanie  $\approx 94.65\%$  budżetu.

k value	best fit	best fit mean	best fit std. deviation	budget use mean
50	9.88	1090.58	2400.09	42.34%
75	8.06	886.17	2057.39	56.76%
<b>100</b>	<b>7.69</b>	<b>364.44</b>	<b>918.76</b>	<b>65.22%</b>
budget/lambda	7.37	493.17	1126.43	99.98%

Tablica 3: Porównanie najlepszych wartości parametru  $k$  dla  $F_6$




Rysunek 5: Wartości najlepszego dopasowania funkcji  $F_6$  wg kryterium  $K$ -iteracji. Najlepszy parametr  $k \approx 100$ , wykorzystanie  $\approx 65.22\%$  budżetu.

Restarty wg kryterium  $K$ -iteracji mają sens. Nie wykorzystując budżetu w pojedynczym uruchomieniu możemy wykorzystać niewykorzystane ewaluacje funkcji w nowym uruchomieniu, co może skutkować uzyskaniem lepszego wyniku.

## Wnioski do kryterium Odchylenia Standardowego

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.15	0.05	0.22	0.12	89.3%
0.14	0.05	0.22	0.14	95.3%
<b>0.13</b>	<b>0.02</b>	<b>0.2</b>	<b>0.09</b>	<b>95.27%</b>
0.12	0.04	0.21	0.12	97.63%

Tablica 4: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_4$

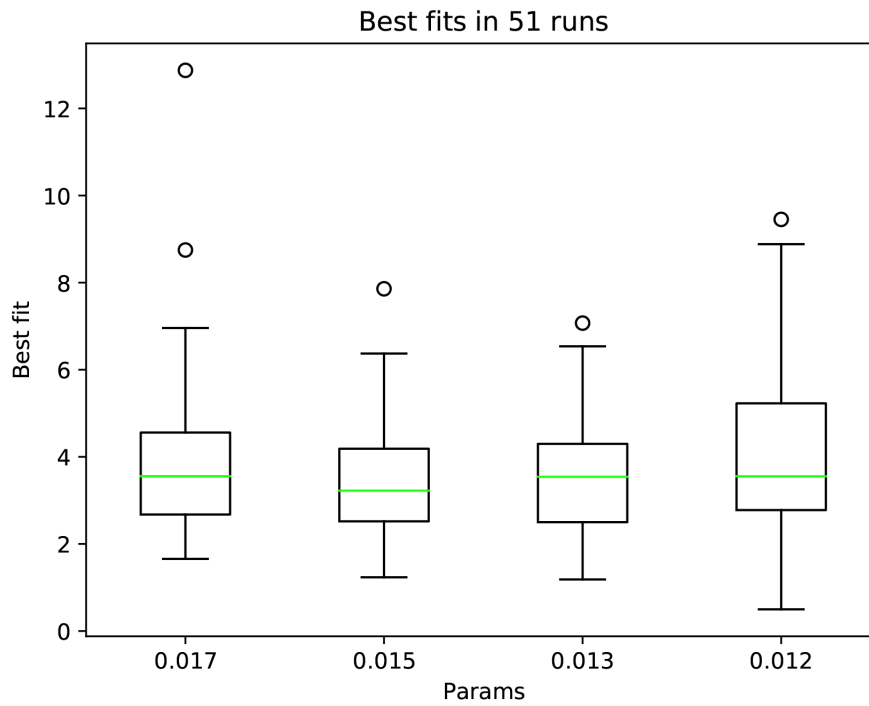


Rysunek 6: Wartości najlepszego dopasowania funkcji  $F_4$  wg kryterium Odchylenia Standardowego. Najlepszy parametr  $\epsilon \approx 0.13$ , wykorzystanie  $\approx 95.27\%$  budżetu.



$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.017	1.66	3.89	1.94	83.7%
<b>0.015</b>	<b>1.23</b>	<b>3.48</b>	<b>1.38</b>	<b>93.03%</b>
0.013	1.18	3.5	1.34	94.6%
0.012	0.5	4.02	1.87	97.92%


Tablica 5: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_5$



Rysunek 7: Wartości najlepszego dopasowania funkcji  $F_5$  wg kryterium Odchylenia Standardowego. Najlepszy parametr  $\epsilon \approx 0.015$ , wykorzystanie  $\approx 93.03\%$  budżetu.

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.25	7.6	972.81	2374.26	56.62%
<b>0.2</b>	<b>7.7</b>	<b>631.97</b>	<b>1646.65</b>	<b>76.59%</b>
0.175	7.9	686.5	1987.23	81.41%
0.1	5.14	929.13	2446.75	99.3%

Tablica 6: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_6$




Rysunek 8: Wartości najlepszego dopasowania funkcji  $F_6$  wg kryterium Odchylenia Standardowego. Najlepszy parametr  $\epsilon \approx 0.2$ , wykorzystanie  $\approx 76.59\%$  budżetu.

Przerwania wg kryterium Odchylenia Standardowego również mają sens.

## Wnioski do kryterium Najlepszy-Najgorszy

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.125	0.1	0.28	0.17	73.41%
0.1	0.05	0.26	0.12	85.76%
<b>0.075</b>	<b>0.06</b>	<b>0.21</b>	<b>0.1</b>	<b>93.59%</b>
0.05	0.04	0.21	0.12	99.3%


Tablica 7: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_4$



Rysunek 9: Wartości najlepszego dopasowania funkcji  $F_4$  wg kryterium Najlepszy-Najgorszy. Najlepszy parametr  $\epsilon \approx 0.075$ , wykorzystanie  $\approx 93.59\%$  budżetu.

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
1.0	1.33	4.37	2.48	88.9%
0.9	0.76	3.78	2.1	89.1%
<b>0.8</b>	<b>1.29</b>	<b>3.19</b>	<b>1.22</b>	<b>98.47%</b>
0.7	1.36	3.61	1.71	98.25%


Tablica 8: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_5$



Rysunek 10: Wartości najlepszego dopasowania funkcji  $F_5$  wg kryterium Najlepszy-Najgroszy. Najlepszy parametr  $\epsilon \approx 0.8$ , wykorzystanie  $\approx 98.47\%$  budżetu.

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
2.0	8.07	1030.86	2437.83	65.55%
1.75	4.67	759.88	2122.63	81%
<b>1.5</b>	<b>8.33</b>	<b>420.16</b>	<b>1069.83</b>	<b>86.58%</b>
1.0	7.68	1489.94	2933.88	99.69%

Tablica 9: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_6$




Rysunek 11: Wartości najlepszego dopasowania funkcji  $F_6$  wg kryterium Najlepszy-Najgorszy. Najlepszy parametr  $\epsilon \approx 1.5$ , wykorzystanie  $\approx 86.58\%$  budżetu.

Przerwania wg kryterium Najlepszy-Najgorszy również mają sens.

## Wnioski do kryterium Wariancji Dopasowania

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.00055	0.05	0.21	0.12	90.22%
0.00045	0.03	0.2	0.11	91.68%
<b>0.0004</b>	<b>0.03</b>	<b>0.18</b>	<b>0.1</b>	<b>96.89%</b>
0.00035	0.04	0.19	0.14	97.67%

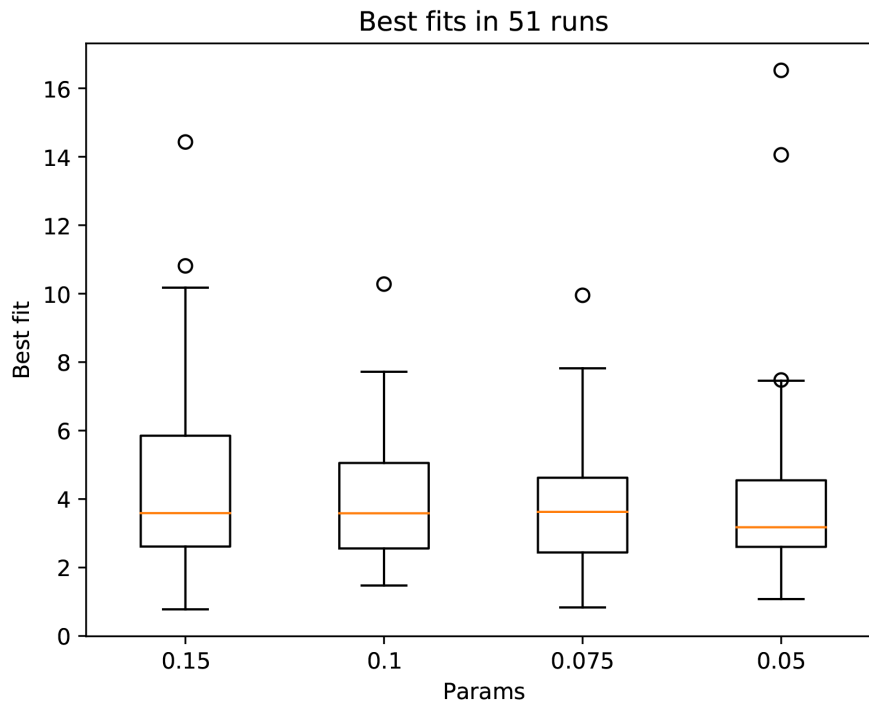
Tablica 10: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_4$



Rysunek 12: Wartości najlepszego dopasowania funkcji  $F_4$  wg kryterium Wariancji Dopasowania. Najlepszy parametr  $\epsilon \approx 0.0004$ , wykorzystanie  $\approx 96.89\%$  budżetu.

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.15	0.78	4.47	2.78	72.52%
0.1	1.47	4.0	1.84	85.24%
<b>0.075</b>	<b>0.83</b>	<b>3.84</b>	<b>1.82</b>	<b>92.95%</b>
0.05	1.08	4.07	2.79	96.18%


Tablica 11: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_5$



Rysunek 13: Wartości najlepszego dopasowania funkcji  $F_5$  wg kryterium Wariacji Dopasowania. Najlepszy parametr  $\epsilon \approx 0.075$ , wykorzystanie  $\approx 92.95\%$  budżetu.

$\epsilon$	best fit	best fit mean	best fit std. deviation	budget use mean
0.8	8.3	560.79	1582.09	46.6%
<b>0.5</b>	<b>6.82</b>	<b>409.4</b>	<b>1225.4</b>	<b>50.01%</b>
0.3	8.43	615.06	1427.96	75.1%
0.1	7.46	524.33	1189.06	98.09%

Tablica 12: Porównanie najlepszych wartości parametru  $\epsilon$  dla  $F_6$



Rysunek 14: Wartości najlepszego dopasowania funkcji  $F_6$  wg kryterium Wariacji Dopasowania. Najlepszy parametr  $\epsilon \approx 0.5$ , wykorzystanie  $\approx 50.01\%$  budżetu.

Przerwania wg kryterium Wariacji Dopasowania również mają sens.



## Dyskusja

kryterium	średnie dopasowanie	odchylenie standardowe	wykorzystanie budżetu
$K$ -iteracji	0.19	0.11	$\approx 96.63\%$
Odchylenie Standardowe	0.2	0.09	$\approx 95.27\%$
Najlepszy-Najgorszy	0.21	0.1	$\approx 93.59\%$
Wariancja Dopasowania	0.18	0.1	$\approx 96.89\%$

Tablica 13: Porównanie kryteriów przerwania dla  $F_4$ .

kryterium	średnie dopasowanie	odchylenie standardowe	wykorzystanie budżetu
$K$ -iteracji	3.32	1.33	$\approx 94.65\%$
Odchylenie Standardowe	3.48	1.38	$\approx 93.03\%$
Najlepszy-Najgorszy	3.19	1.22	$\approx 98.47\%$
Wariancja Dopasowania	3.84	1.82	$\approx 92.95\%$

Tablica 14: Porównanie kryteriów przerwania dla  $F_5$ .

kryterium	średnie dopasowanie	odchylenie standardowe	wykorzystanie budżetu
$K$ -iteracji	364.44	918.76	$\approx 65.22\%$
Odchylenie Standardowe	631.97	1646.65	$\approx 76.59\%$
Najlepszy-Najgorszy	420.16	1069.83	$\approx 86.58\%$
Wariancja Dopasowania	409.4	1225.4	$\approx 50.01\%$


Tablica 15: Porównanie kryteriów przerwania dla  $F_6$ .

Dla funkcji  $F_4$  i  $F_6$  najlepiej zastosować kryterium Wariancji Dopasowania. Dla funkcji  $F_5$  najlepiej zastosować kryterium Najlepszy-Najgorszy. Zauważmy także, że dla funkcji  $F_6$  najlepszy wynik jest osiągalny przy relatywnie niskim wykorzystaniu budżetu (w porównaniu do pozostałych kryteriów).

## 8 Podsumowanie

Projekt wprowadzający w tematykę algorytmów ewolucyjnych. Dzięki implementacji przykładowej strategii ewolucyjnej poznano istotę algorytmów ewolucyjnych. Implementacja przykładowych kryteriów przerywania pracy algorytmu pozwoliła na analizę procesu optymalizacji funkcji i sensowności stosowania tychże przerwania.

## 9 Powiązane linki

 [Repozytorium projektowe](#)

## 10 Bibliografia

GHOREISHI, Seyyedeh Newsha; CLAUSEN, Anders; JØRGENSEN, Bo Nørregaard. Termination Criteria in Evolutionary Algorithms: A Survey. In: IJCCI. 2017. p. 373-384.

SUGANTHAN, Ponnuthurai N., et al. Problem definitions and evaluation criteria for the CEC 2005 special session on real-parameter optimization. KanGAL report, 2005, 2005005.2005: 2005.